

Detecção de Doenças em Plantas com Machine Learning

1st Gabriel Fernando Faria De Oliveira
Engenharia de Computação (EMC)
Universidade Federal de Goiás (UFG)
Goiânia, Brasil
fnaticrisk@discente.ufg.br

2nd Guilherme Henrique dos Reis
Inteligência Artificial (INF)
Universidade Federal de Goiás (UFG)
Goiânia, Brasil
guilherme_reis@discente.ufg.br

3rd Gustavo dos Reis Oliveira
Inteligência Artificial (INF)
Universidade Federal de Goiás (UFG)
Goiânia, Brasil
gustavo.reis2@discente.ufg.br

4th Isadora Stéfany R.R. Mesquita
Inteligência Artificial (INF)
Universidade Federal de Goiás (UFG)
Goiânia, Brasil
isadora.mesquita@discente.ufg.br

5th Pedro Martins Bittencourt
Inteligência Artificial (INF)
Universidade Federal de Goiás (UFG)
Goiânia, Brasil
bittencourtpedro@discente.ufg.br

Abstract—Neste artigo, apresenta-se uma aplicação da Visão Computacional voltada para problemas sociais, especificamente a detecção de doenças em plantas, que acarretam consideráveis prejuízos econômicos aos agricultores. Explora-se como essa abordagem tecnológica pode ser uma solução promissora para identificar e monitorar doenças nas plantações, proporcionando maior eficiência e auxiliando na redução das perdas agrícolas. A integração da Visão Computacional nesse contexto evidencia o potencial dessa tecnologia para impulsionar a agricultura de forma mais sustentável e resiliente, fortalecendo a segurança alimentar global.

Index Terms—Agricultura, aprendizado de máquina, detecção de objetos, inteligência artificial, patologia vegetal, visão computacional.

I. INTRODUÇÃO

A agricultura é a espinha dorsal da economia global, desempenhando um papel essencial na segurança alimentar e nos meios de subsistência em todo o mundo. No entanto, o setor enfrenta desafios significativos, particularmente no domínio das doenças de plantas, que representam uma grave ameaça para a produção e a qualidade das colheitas. Os métodos tradicionais de detecção de doenças em plantas, embora eficazes até certo ponto, geralmente requerem mão de obra extensa, tempo e especialização. A necessidade de soluções mais rápidas, precisas e escaláveis nunca foi tão pronunciada. Este relatório concentra-se em uma dessas soluções promissoras: a implementação de técnicas de visão computacional para a detecção de doenças de plantas.

A visão computacional, um campo que permite às máquinas interpretar e tomar decisões com base em dados visuais, oferece um potencial incomparável na detecção e diagnóstico precoce de doenças de plantas. Ela introduz uma abordagem transformadora ao permitir o monitoramento e análise não invasiva e em tempo real das culturas. Por meio do uso de vários algoritmos e tecnologias de imagem, a visão computacional pode detectar mudanças sutis na cor, textura e morfologia

das folhas das plantas e outras partes, indicando o início de doenças que podem ser negligenciadas pelo olho humano.

A integração da visão computacional na fitopatologia representa uma confluência de tecnologia e biologia, onde algoritmos podem ser treinados para reconhecer padrões específicos de doenças, tornando a detecção de doenças mais precisa e eficiente. Desde a utilização de técnicas simples de análise de imagem até a implementação de modelos sofisticados de aprendizado profundo, o campo da visão computacional abre novos horizontes na gestão e controle de doenças de plantas.

Este relatório tem como objetivo fornecer uma exploração aprofundada das atuais aplicações, metodologias, sucessos e desafios do uso da visão computacional na detecção de doenças de plantas. Analisaremos várias técnicas, desde a análise básica de imagem até modelos avançados de aprendizado de máquina, e discutiremos suas aplicações práticas e limitações em diferentes contextos agrícolas. Além disso, ofereceremos insights sobre pesquisas em andamento, perspectivas futuras e como esses avanços tecnológicos poderiam remodelar a paisagem da agricultura, levando a práticas agrícolas mais sustentáveis e resilientes. Ao apresentar uma análise detalhada, este relatório se esforça para contribuir com conhecimento valioso para as comunidades agrícola e tecnológica, destacando o papel crucial que a visão computacional pode desempenhar na revolução da detecção e gestão de doenças de plantas.

II. FUNDAMENTOS TEÓRICOS

O estudo da visão computacional aplicada à detecção de doenças em plantas é de suma importância para aprimorar a agricultura moderna. Ao permitir a identificação precoce e precisa de enfermidades em culturas, essa abordagem tecnológica contribui significativamente para a segurança alimentar, evitando perdas substanciais na produção agrícola. Além disso, a utilização da visão computacional nesse contexto promove a sustentabilidade ambiental, ao reduzir a necessidade de

aplicação excessiva de agroquímicos. Através dos avanços tecnológicos decorrentes desse estudo, é possível desenvolver soluções mais eficientes e resilientes, tornando a agricultura mais adaptada aos desafios globais e capaz de suprir as demandas crescentes da população mundial.

A abordagem para a resolução desse problema consiste em empregar algoritmos e técnicas avançadas, aproveitando as vastas possibilidades oferecidas pelo dataset de alta qualidade conhecido como Digipathos. Esse conjunto de dados contém imagens de plantas afetadas por diversas doenças, garantindo uma ampla diversidade de casos para o treinamento e a validação do modelo. Essa seleção criteriosa de dados é fundamental para o desenvolvimento de um modelo preciso e robusto, capaz de lidar efetivamente com a detecção de doenças em diferentes contextos agrícolas.

Posteriormente, procede-se à aplicação de técnicas de extração de características, com o propósito de transformar as imagens em representações numéricas que capturem informações relevantes, tais como texturas, formas e cores. Essas características extraídas constituem um conjunto de atributos que caracterizam cada imagem, tornando-as adequadas para serem utilizadas no processo de aprendizado de máquina.

Dentre as técnicas de visão computacional aplicáveis à detecção de doenças em imagens de plantas, destacam-se a detecção de bordas, a segmentação de imagens e os descritores de características. A detecção de bordas consiste em identificar regiões de mudanças abruptas nos níveis de intensidade da imagem, sendo útil para identificar contornos e padrões distintos associados a doenças.

A segmentação de imagens visa dividir a imagem em regiões significativas, possibilitando a separação de áreas saudáveis das afetadas por doenças. Essa técnica é essencial para isolar e analisar as áreas danificadas, contribuindo para a precisão da detecção.

Por sua vez, os descritores de características são algoritmos que permitem extrair informações relevantes da imagem, como texturas e padrões distintivos. Entre os descritores mais utilizados, encontram-se o Histograma de Gradientes Orientados (HOG), que codifica a distribuição de gradientes de intensidade, e as Redes Neurais Convolucionais (CNN), modelos de aprendizado profundo capazes de aprender características complexas diretamente das imagens.

A combinação adequada dessas técnicas pode resultar em um pipeline eficiente para a detecção de doenças em imagens de plantas. Ao extrair características representativas das imagens e utilizá-las como entrada para modelos de aprendizado de máquina, é possível desenvolver sistemas precisos e confiáveis para auxiliar os agricultores na identificação e controle das enfermidades, promovendo uma abordagem mais sustentável e eficiente na agricultura.

III. METODOLOGIA

1. Pré-processamento de Dados:

Antes de iniciar o treinamento, os dados foram pré-processados. Navegamos por cada diretório de imagens e

identificamos as plantas e as respectivas doenças com base nos nomes dos diretórios. Depois de categorizar as imagens, removemos as classes que tinham apenas uma imagem, pois essas classes não seriam úteis para o treinamento e validação do modelo.

2. Divisão de Dados:

Os dados foram divididos em conjuntos de treinamento e validação usando uma divisão de 80-20. Garantimos que cada classe estivesse representada em ambos os conjuntos.

3. Augmentação de Dados:

Para melhorar o desempenho do modelo e garantir que ele não se ajustasse muito a um conjunto de treinamento específico, aplicamos técnicas de augmentação de imagem, como rotação, zoom e inversão horizontal, usando o ImageDataGenerator do TensorFlow.

4. Modelagem:

Utilizamos a arquitetura VGG16 como nosso modelo base. Esta é uma arquitetura popular e amplamente usada em tarefas de visão computacional. Carregamos os pesos pré-treinados do VGG16 e adicionamos camadas densas personalizadas na extremidade para realizar a classificação.

As camadas do VGG16 foram congeladas para manter os pesos durante o treinamento, e apenas as camadas adicionadas foram treinadas usando nosso conjunto de dados. O modelo foi compilado usando o otimizador Adam e a perda de entropia cruzada categórica.

5. Treinamento:

O modelo foi treinado usando o conjunto de treinamento por 30 épocas. Monitoramos tanto a acurácia quanto a perda nos conjuntos de treinamento e validação para acompanhar o desempenho do modelo ao longo do tempo. Após o treinamento, os resultados foram visualizados usando gráficos de acurácia e perda ao longo das épocas.

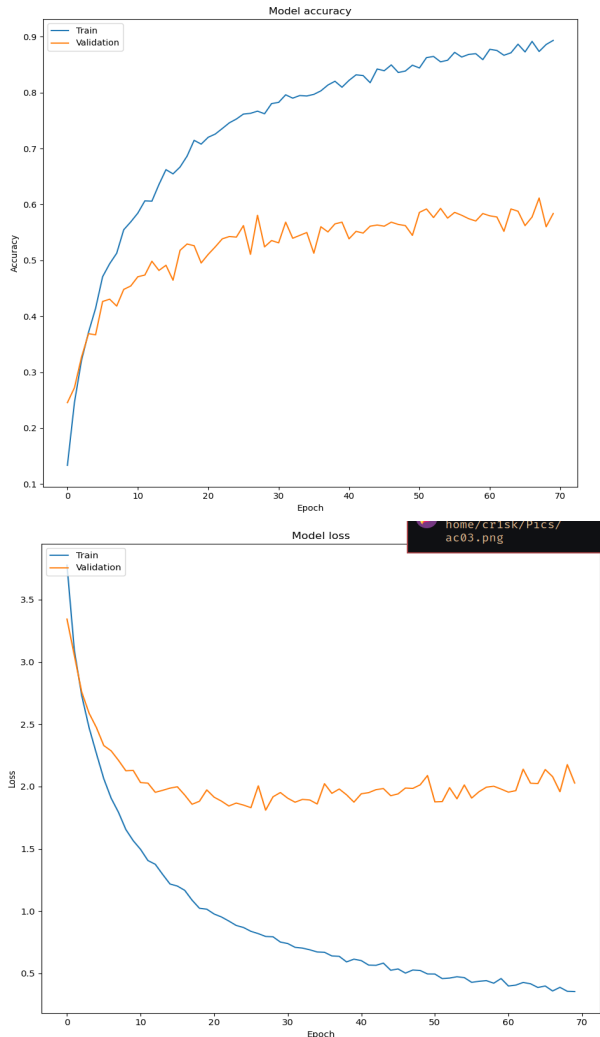
6. Avaliação:

Após o treinamento, utilizamos o conjunto de validação para avaliar o desempenho do modelo. Uma matriz de confusão foi gerada para visualizar o desempenho do modelo em diferentes classes, e métricas como precisão, recall e F1-score foram calculadas para fornecer uma avaliação quantitativa do modelo.

7. Inferência:

Para testar o modelo em imagens novas, foi desenvolvido um script de inferência que carrega o modelo treinado, processa uma imagem de entrada e retorna a classe prevista para essa imagem.

IV. RESULTADOS E CONCLUSÕES



Nos gráficos gerados após o treinamento, observamos as seguintes tendências:

Perda (Loss) do Modelo: A perda durante o treinamento mostrou-se significativamente menor em comparação com a perda durante a validação. Especificamente, na época 70, a perda de treinamento foi de 0,3, enquanto a perda de validação foi substancialmente mais alta, marcando 2.

Acurácia do Modelo: No que diz respeito à acurácia, o modelo apresentou um desempenho bem melhor no conjunto de treinamento em comparação com o conjunto de validação. Na época 70, a acurácia de treinamento foi de 0,87, enquanto a acurácia de validação foi de 0,58.

Sobreajuste (Overfitting): A diferença significativa entre a perda de treinamento e validação, assim como a discrepância na acurácia entre os dois conjuntos, sugere que o modelo pode estar sofrendo de sobreajuste. Isso significa que o modelo se ajustou muito bem aos dados de treinamento, mas não generaliza eficazmente para novos, dados não vistos.

Potencial para Melhorias: Para combater o sobreajuste, técnicas adicionais podem ser consideradas no futuro, como introduzir regularização, aumentar a augmentação de dados, ou

tentar uma abordagem de transferência de aprendizado mais aprofundada.

Aplicabilidade Prática: Mesmo com um desempenho inferior no conjunto de validação, a acurácia de 0,58 indica que o modelo tem potencial em cenários práticos. No entanto, para aplicações críticas, é essencial investigar e melhorar a robustez do modelo antes de qualquer implementação em campo.

Recomendações Futuras: Seria benéfico realizar mais experimentos, talvez com diferentes arquiteturas ou ajustando hiperparâmetros, para alcançar um equilíbrio entre a acurácia de treinamento e validação. Além disso, seria útil incluir mais dados, especialmente para classes que podem ter representação insuficiente, para fortalecer a capacidade de generalização do modelo.

REFERENCES

- [1] Patil, J.K., & Kumar, R. (2011). Advances in image processing for detection of plant diseases. *Journal of Advanced Bioinformatics Applications and Research*, 2(2), 135-141.
- [2] Mahlein, A.K., Rumpf, T., Welke, P., Dehne, H.W., Plümer, L., Steiner, U., & Oerke, E.C. (2012). Development of spectral indices for detecting and identifying plant diseases. *Remote Sensing of Environment*, 128, 21-30.
- [3] Sannakki, S.S., Rajpurohit, V.S., Nargund, V.B., & Kulkarni, P. (2013). Diagnosis and classification of grape leaf diseases using neural networks. In *Proceedings of the 4th international conference on computing, communications and networking technologies (ICCCNT)*.
- [4] Pantazi, X.E., Moshou, D., Alexandridis, T., Whetton, R.L., & Mouazen, A.M. (2016). Wheat yield prediction using machine learning and advanced sensing techniques. *Computers and Electronics in Agriculture*, 121, 57-65.
- [5] Kamilaris, A., & Prenafeta-Bold, F.X., (2018). Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture*, 147, 70-90.